

26.5.28 Meeting 10 交接 Rprompt调参

一. 修了一个小bug

loss 是 `nan` 时没有给 `test_acc` 赋值，所以直接退出了

做一个最小修复，让失败参数记为 `nan`，不要把整个 sweep 中断

```
sed -i "/if not math.isnan(loss):/i      test_acc = float('nan')" prompt_graph/tasker/node_task.py
```

二.生成Rprompt调参shell（但是最终没用，因为表现差距很大需细搜，就手动调了）

```
"/home/tony/LnL/DFS_HK3/run_RPrompt_GraphCL_Cora_sweep.sh"
```

三.Rprompt调参

最开始广泛调参表现很差，决定从最保守版本开始精细调参

1.最保守版本调参

组别	p_plus	attention	pt_threshold	prompt_lr	weight_mse	weight_kl	weight_const
manual_1	开	关	0.0	0.001	0.0	0.0	0.0
manual_2	开	开	0.0	0.001	0.0	0.0	0.0
manual_3	关	关	0.0	0.001	0.0	0.0	0.0

共同设置：

```
dataset = Cora
prompt_type = RobustPrompt-T
pretrain = GraphCL
gnn_type = GCN
hid_dim = 256
num_layer = 2
shot_num = 5
run_split = 1
seed = 1 2 3 4 5
attack_method = Meta_Self-0.0
filter_mode = original
epochs = 200
```

manual_1: p_plus 开, attention 关, 正则全关
Acc = 0.2403 ± 0.0049

manual_2: p_plus 开, attention 开, 正则全关
Acc = 0.1435 ± 0.0346

manual_3: p_plus 关, attention 关, 正则全关
Acc = 0.1848 ± 0.0070

GPPT 对照
Acc = 0.4350 ± 0.0000

1. attention 在这里明显有害: 0.2403 -> 0.1435
2. p_plus 是有帮助的: 0.1848 -> 0.2403
3. 正则和剪枝先不开太多
4. RPrompt-T 目前最好也只有 0.24, 离 GPPT 的 0.435 还差很多

2.小范围扫：

固定：
--no_attention
--weight_kl 0.0
--weight_mse 0.0
--weight_constraint 0.0
保留 p_plus 默认开启

重点扫：
prompt_lr: 0.0003, 0.001, 0.003, 0.005
pt_threshold: 0.0, 0.05, 0.1, 0.2

参数	含义	影响
prompt_lr	prompt 和 answering head 的学习率	控制 prompt/分类头每一步更新多大
pt_threshold	边剪枝的 cosine 相似度阈值	控制哪些边会被保留，哪些边会被删掉 只有相似度 >= pt_threshold 的边会被保留 相似度 < pt_threshold 的边会被剪掉

prompt_lr	pt_threshold=0.0	pt_threshold=0.05	pt_threshold=0.1	pt_threshold=0.2
0.0003	0.1907±0.0069	0.1908±0.0082	0.1887±0.0046	0.1870±0.0060
0.001	0.2403±0.0049	0.2555±0.0040	0.2582±0.0110	0.2673±0.0038
0.003	0.2803±0.0200	0.2880±0.0078	0.2845±0.0211	0.2863±0.0226
0.005	0.2723±0.0229	0.2898±0.0232	0.2558±0.0172	0.2940±0.0139

目前最好：

prompt_lr = 0.005
pt_threshold = 0.2
Acc = 0.2940 ± 0.0139

3.当前最好附近细搜：

```
prompt_lr: 0.004, 0.005, 0.006, 0.008
pt_threshold: 0.15, 0.2, 0.25, 0.3
```

仍然固定：

```
--no_attention
--weight_kl 0.0
--weight_mse 0.0
--weight_constraint 0.0
```

prompt_lr	pt=0.15	pt=0.20	pt=0.25	pt=0.30
0.004	0.2773±0.0318	0.2915±0.0175	0.2915±0.0033	0.2770±0.0131
0.005	0.2867±0.0191	0.2853±0.0116	0.2662±0.0158	0.2835±0.0176
0.006	0.2818±0.0206	0.2893±0.0261	0.2890±0.0070	0.2755±0.0147
0.008	0.2917±0.0510	0.2358±0.0364	0.2350±0.0452	0.3108±0.0323

当前细搜最好：

```
prompt_lr = 0.008
pt_threshold = 0.30
Acc = 0.3108 ± 0.0323
```

但注意它的标准差偏大，稳定性一般。更稳的组合是：

```
prompt_lr = 0.004
pt_threshold = 0.25
Acc = 0.2915 ± 0.0033
```

和上一轮最好对比：

```
上一轮最好: lr=0.005, pt=0.20, Acc=0.2940±0.0139
这一轮最好: lr=0.008, pt=0.30, Acc=0.3108±0.0323
```

分析

整体趋势是：

- 1. lr=0.0003 太小，基本只有 0.19 左右。
- 2. lr=0.001 提升到 0.24-0.27。
- 3. lr=0.003-0.006 基本稳定在 0.28-0.29。
- 4. lr=0.008 出现分化：pt=0.2/0.25 很差，但 pt=0.3 最高。

pt_threshold 方面：

```
pt=0.0 太弱，最好也只有 0.28 左右
pt=0.2-0.3 更有希望
pt=0.25 在 lr=0.004/0.006 下比较稳定
pt=0.3 在 lr=0.008 下最好，但方差较大
```

目前结论：

```
RPrompt-T 最优已从 0.2403 提升到 0.3108 ,但仍低于 GPPT 0.4350
attention 不开
正则暂时不开
p_plus 保留
```

4.在prompt_lr和pt_threshold基础上细搜其他参数

这轮 manual_reg 是在两套基础参数上扫：

```
A: lr=0.004, pt_threshold=0.25
B: lr=0.008, pt_threshold=0.30
```

共同固定：

```
p_plus 开
attention 关
weight_constraint = 0.0
filter_mode = original
Meta_Self-0.0
```

A 组：lr=0.004, pt=0.25

weight_mse \ weight_kl	0.0	0.01	0.05	0.1
0.0	0.2960±0.0070	0.2720±0.0185	0.2730±0.0382	0.2785±0.0245
0.01	0.2902±0.0300	0.2935±0.0304	0.2792±0.0147	0.2665±0.0177
0.05	0.2920±0.0398	0.3023±0.0172	0.2965±0.0372	0.3177±0.0446
0.1	0.2797±0.0064	0.2807±0.0057	0.2820±0.0128	0.3230±0.0305

A 组最好：

```
lr=0.004, pt=0.25, mse=0.1, kl=0.1
Acc = 0.3230 ± 0.0305
```

A 组最稳且还不错：

```
lr=0.004, pt=0.25, mse=0.0, kl=0.0
Acc = 0.2960 ± 0.0070
```

B 组：lr=0.008, pt=0.30

weight_mse \ weight_kl	0.0	0.01	0.05	0.1
0.0	0.2903±0.0739	0.2882±0.0314	0.2518±0.0274	0.2460±0.0380
0.01	0.2120±0.0446	0.2900±0.0076	0.2540±0.0285	0.2785±0.0604
0.05	0.2385±0.0433	0.2590±0.0617	0.3095±0.0859	0.2328±0.0362
0.1	0.2358±0.0434	0.2378±0.0461	0.2592±0.0592	0.3427±0.0589

B 组最好：

```
lr=0.008, pt=0.30, mse=0.1, kl=0.1
Acc = 0.3427 ± 0.0589
```

B 组最稳且还不错：

```
lr=0.008, pt=0.30, mse=0.01, kl=0.01
Acc = 0.2900 ± 0.0076
```

总体排名

排名	lr	pt_threshold	weight_mse	weight_kl	结果
1	0.008	0.30	0.1	0.1	0.3427±0.0589
2	0.004	0.25	0.1	0.1	0.3230±0.0305
3	0.004	0.25	0.05	0.1	0.3177±0.0446
4	0.008	0.30	0.05	0.05	0.3095±0.0859
5	0.004	0.25	0.05	0.01	0.3023±0.0172

分析

这轮说明正则不是完全没用

之前全关正则时最好大概是：

```
0.3108±0.0323
```

现在加上小\中等正则后最高到了：

```
0.3427±0.0589
```

但最高这组方差很大，说明不够稳

候选 A，最高：
lr=0.008, pt=0.30, mse=0.1, kl=0.1, no_attention
Acc=0.3427±0.0589

候选 B，较稳：
lr=0.004, pt=0.25, mse=0.1, kl=0.1, no_attention
Acc=0.3230±0.0305

5. 稳定参数跑不同浓度污染图

```
lr=0.004
pt_threshold=0.25
weight_mse=0.1
weight_kl=0.1
no_attention
```

ptb	RPrompt-T stable
0.0	0.3213±0.0274
0.05	0.1867±0.0150
0.1	0.0883±0.0047
0.15	0.1037±0.0120
0.2	0.1557±0.0164
0.25	0.1562±0.0266

1. clean 上参数是复现的：之前 **0.3230±0.0305**，现在 **0.3213±0.0274**。
2. 但一加攻击，性能快速掉到接近/低于随机。
3. RPrompt-T 当前实现没有表现出预期鲁棒性。

6. 稳定参数跑不同浓度污染图-单独细搜

在 `ptb=0.05` 或 `ptb=0.1` 上单独扫

```
lr: 0.001, 0.003, 0.004, 0.005
pt_threshold: 0.0, 0.05, 0.1, 0.2
mse/kl: 先全关
no_attention
```

污染图专门调参，固定：

```
p_plus 开
attention 关
weight_mse = 0
weight_kl = 0
weight_constraint = 0
filter_mode = original
```

只扫：

```
ptb = 0.05, 0.1
prompt_lr × pt_threshold
```

Meta_Self-0.05

prompt_lr	pt=0.0	pt=0.05	pt=0.1	pt=0.2	pt=0.3
0.001	0.1932±0.0040	0.1950±0.0025	0.1952±0.0039	0.1910±0.0032	0.1977±0.0203
0.003	0.2200±0.0380	0.2163±0.0387	0.2000±0.0214	0.2215±0.0436	0.2210±0.0118
0.004	0.2275±0.0259	0.1942±0.0367	0.1968±0.0312	0.1977±0.0448	0.2032±0.0095
0.005	0.1960±0.0295	0.1800±0.0213	0.1905±0.0294	0.1878±0.0271	0.1898±0.0363
0.008	0.1525±0.0184	0.1572±0.0293	0.1700±0.0255	0.1895±0.0304	0.1405±0.0150

0.05 上最好：

```
lr=0.004, pt=0.0
Acc = 0.2275±0.0259
```

lr=0.003, pt=0.3 也不错且更稳：

```
lr=0.003, pt=0.3
Acc = 0.2210±0.0118
```

Meta_Self-0.1

prompt_lr	pt=0.0	pt=0.05	pt=0.1	pt=0.2	pt=0.3
0.001	0.1260±0.0205	0.1217±0.0195	0.1265±0.0218	0.1170±0.0169	0.1375±0.0161
0.003	0.1210±0.0274	0.1175±0.0334	0.1185±0.0297	0.1105±0.0220	0.1248±0.0342
0.004	0.1062±0.0198	0.1080±0.0197	0.1033±0.0168	0.1013±0.0167	0.1202±0.0324
0.005	0.1257±0.0138	0.1078±0.0117	0.1005±0.0042	0.1147±0.0083	0.1380±0.0365
0.008	0.1485±0.0407	0.1223±0.0015	0.1513±0.0271	0.1345±0.0209	0.1832±0.0471

0.1 上最好：

```
lr=0.008, pt=0.3
Acc = 0.1832±0.0471
```

更稳但低一点：

```
lr=0.008, pt=0.1
Acc = 0.1513±0.0271
```

结论：

1. 污染图最好参数和 clean 最好参数不一致。
2. 低污染 ptb=0.05 偏好 lr=0.003~0.004, pt 不宜太大。
3. ptb=0.1 反而只有 lr=0.008, pt=0.3 明显高一些，但不稳定。
4. 目前 RPrompt-T 在 Meta_Self 污染图上没有显示出强鲁棒性。

7.污染图参数细搜，加正则

Meta_Self-0.05

weight_mse \ weight_kl	0.0	0.05	0.1
0.0	0.2125±0.0426	0.2183±0.0370	0.1880±0.0508
0.05	0.1933±0.0197	0.1972±0.0271	0.1878±0.0294
0.1	0.1795±0.0401	0.1887±0.0213	0.1965±0.0316

0.05 最好：

```
lr=0.004, pt=0.0, mse=0.0, kl=0.05
```

Acc = 0.2183±0.0370

不过它还低于上一轮 noReg 里的最好：

上一轮 ptb=0.05 最好: lr=0.004, pt=0.0, noReg = 0.2275±0.0259

所以对 ptb=0.05，正则没有带来提升。

Meta_Self-0.1

weight_mse \ weight_kl	0.0	0.05	0.1
0.0	0.1712±0.0419	0.1462±0.0548	0.1408±0.0372
0.05	0.1660±0.0669	0.1118±0.0133	0.1393±0.0127
0.1	0.1467±0.0133	0.1383±0.0235	0.1642±0.0440

0.1 最好：

lr=0.008, pt=0.3, mse=0.0, kl=0.0
Acc = 0.1712±0.0419

也低于上一轮 noReg 的最好：

上一轮 ptb=0.1 最好: lr=0.008, pt=0.3, noReg = 0.1832±0.0471

所以对 ptb=0.1，正则也没有提升。

结论

这轮结果比较明确：

1. 污染图上加 weight_mse / weight_kl 没有帮助
2. 对 ptb=0.05 和 ptb=0.1，最好结果仍然来自 noReg
3. KL 正则 在污染图上大多拉低性能
4. MSE 正则也没有稳定提升，尤其 mse=0.1 往往更差

四.总结

1.

污染浓度	0.00	0.05	0.10	0.15	0.20	0.25
GraphCL + GPPT Accuracy	0.4350	0.2790	0.0700	0.0740	0.0280	0.0350

在 clean / Meta_Self-0.0 上：

方法	结果
GPPT	0.4350±0.0000
RobustPrompt-T best clean	0.3427±0.0589
RobustPrompt-T stable clean	0.3213±0.0274

但是在高浓度污染情况下，RobustPrompt-T 表现会更好

2. RobustPrompt-T 的最佳 clean 参数

最高 clean 结果：


```
prompt_type = RobustPrompt-T
prompt_lr = 0.008
pt_threshold = 0.30
weight_mse = 0.1
weight_kl = 0.1
weight_constraint = 0.0
p_plus = True
attention = False
filter_mode = original
```

结果：

Meta_Self-0.0: 0.3427±0.0589

但这组方差较大，而且后续污染图复现 clean 时掉到：

0.2598±0.0194

所以它不够稳定。

3. 更稳定的 clean 参数

推荐作为主实验参数：

```
prompt_lr = 0.004
pt_threshold = 0.25
weight_mse = 0.1
weight_kl = 0.1
weight_constraint = 0.0
p_plus = True
attention = False
filter_mode = original
```

clean 结果：

调参阶段：0.3230±0.0305
污染全浓度复跑 clean: 0.3213±0.0274

这组可复现性更好。

4. 固定 stable 参数跑全部污染浓度

ptb	RobustPrompt-T stable
0.0	0.3213±0.0274
0.05	0.1867±0.0150
0.1	0.0883±0.0047
0.15	0.1037±0.0120
0.2	0.1557±0.0164
0.25	0.1562±0.0266

5. 污染图 per-ptb 调参的最好结果

ptb	最佳参数	结果
0.05	lr=0.004, pt=0.0, mse=0, kl=0, no_attention	0.2275±0.0259
0.1	lr=0.008, pt=0.3, mse=0, kl=0, no_attention	0.1832±0.0471

这说明：

针对污染图单独调参，RPrompt-T 能小幅提升