

鲁棒图提示学习项目及其历程总结

1. 项目概述

本项目旨在探索并构建鲁棒的图提示学习（Graph Prompt Learning）模型范式。面对图数据中存在的结构与特征扰动，研究重点围绕图神经网络的预训练机制、Prompt Learning设计方法以及针对下游任务的防御过滤模块展开。

本文档对项目的整体技术框架、前期推进历程以及近期的预训练超参数调优实验与Prompt Learning实验进行了一定的总结。

2. 项目定位与研究范围

当前，项目覆盖了从基础骨干网络到结合了预训练设计和提示学习设计的防御机制，具体如下：

- Backbone：考虑GCN、GAT、GIN、GraphSAGE、GraphTransformer等；
- Pretrain：考虑GraphCL、GraphMAE、Edgepred_Gprompt以及MultiGprompt等；
- 下游任务：NodeTask, GraphTask, 及所谓LinkTask；
- Prompt Learning：考虑GPPT、All-in-one、Gprompt、GPF、GPF-plus及RobustPrompt等；
- 攻击：few-shot Meta_Self等攻击方式；
- 防御：针对RobustPrompt的不同Filter展开对比研究。

3. 技术框架与代码结构

代码整体以模块化设计：不同预训练策略、不同Prompt Learning方法及不同过滤器

3.1 核心目录结构

项目的核心逻辑集中于prompt_graph/目录下，包含以下主要子模块：

- model/：各类GNN backbone。
- prompt/：各类prompt模块的实现。
- pretrain/：预训练方法的实现。

- tasker/: 下游任务（Node、Graph、Link）的训练与评估流程控制。
- filters/: RobustPrompt / GPPT 可接入的边过滤模块。
- evaluation/、data/、utils/: 分别负责模型评估、数据处理及通用工具（如 loss、seed 设置、PGD 等）。
- data_attack_fewshot/ 负责**旧版本**干净数据及各污染浓度下meta_attack攻击数据的加载；
- data_pyg/负责**train-test-split修正后**的干净数据及各污染浓度下meta_attack攻击数据的加载；
- 预训练权重及日志分别输出至 pre_trained_model/、pre_trained_model_raw/及 logs/ 目录。

3.2 运行

- 预训练：由 MyPretrain.py 负责入口，根据配置分发至不同的预训练类。
- 下游任务：由 MyTask.py 统一入口，参数集中定义于 prompt_graph/utils/get_args.py。
- 任务封装：BaseTask 统一负责初始化 loss、GNN、prompt 及 optimizer；随后 NodeTask 或 GraphTask 承接并处理具体级别的任务流程。

3.3 拓展或修改

若需对组件拓展或修改，可参考定位以下位置：

- 修改/新增 Backbone：需在 prompt_graph/model/ 增加实现，并在 task.py 中的初始化方法添加对应分支。
- 修改 / 新增 Prompt：定位至 prompt_graph/prompt/ 进行类定义，随后在 BaseTask.initialize_prompt() 中注册。
- 修改/新增 Filter：在 prompt_graph/filters/ 下编写模块，并在 filter_factory.py 中进行注册供上层调用。
-

4. 推进历程

4.1 第一次组会

开展前期的论文阅读与团队分工；将项目初步定调为“鲁棒的图提示学习（Robust Graph Prompt Learning）”；并布置后续所需的深层文献调研任务。

4.2 第二次组会

重点讨论了 GPromptShield 的节点分类机制，以及模拟 BFS/DFS 兼容同构异构图的技术可能性。初步形成三条未来探索方向：

- 以GPromptShield 为骨架模型，设计高鲁棒性版本。
- 探索统一范式，使 target model 能够同时兼容 feature-based 和 structure-based 特性。
- 研发新的 filtering 方法，使其兼顾同构图（homophilic graph）与异构图（heterophilic graph）。

4.3 第三次组会

确认并延续上一阶段确定的三大探索方向。在实验操作细节上，明确指出 few-shot (即 k-shot) 的污染图需要借助 generate_few_shot_attack.py 脚本生成。会议还强调需注意区分 inductive 与 transductive learning 场景，并确认可直接基于干净图直接生成所需污染图。

4.4 第四次组会

汇报了在 5% 边污染率及 k=5 设定下，Cora 与 Chameleon 数据集污染图的初步生成情况。团队讨论了在未导入预训练权重的情况下，直接进行节点分类实验的表现；确认后续需要将污染率扩展到 10%、15%、20%，并强调必须先使用普通的 GCN 模型检验污染数据是否有效，之后再开展正式的提示学习实验。针对初步实验中异常低下的表现，明确其缺乏参考价值，必须回退至各模块进行系统性 debug。

4.5 2026年4月阶段记录

4月19日：已成功配置校内远程计算资源，完成部分污染图的生成与虚拟环境配置。确定了在现有鲁棒方法上进行修改并开展多组对比实验的目标。鉴于初步跑通的实验结果未达到相关论文所展示的基准水平，团队决定回归基础，参考 ProG (A Graph Prompt Learning Benchmark) 等系统性评估框架，对代码进行逐模块检查。

4月29日：决定重点排查对比实验表现不理想的深层原因。将排查核心聚焦于 GraphCL预训练与 Prompt Learning 的超参数设置、模型的训练充分性，以及与原论文的逐模块对照检查。开始着手研究 GraphCL 的预训练权重，并尝试生成并输出多组不同配置的权重以供筛选。

5. 后续实验设计与结果整理

5.1 GraphCL 预训练超参数探索

为排查预训练阶段可能存在的瓶颈，项目以 SVC Accuracy 模拟下游任务表现，开展了一系列 GraphCL 超参数对比实验。实验变量包括：

- Augmentations: dropN (Drop Node)、permE (Permute Edge)、maskN等不同配对；
- 数据增强比例：0.2、0.3；
- 学习率：0.01、0.005；

- Epochs: 50、100、150、200。

实验趋势提炼：

- 不同的数据增强组合对预训练质量影响显著， 其中 dropN + permE 组合表现出较好的适应性， 被列为后续重点关注组合。
- 在增强比例方面， Ratio = 0.3 的设定整体表现优于 0.2， 更值得深入考察。
- 我们不想引入欠拟合，故关闭了early stop的设计。期望中，随着epoch的加深，模型表现趋于稳定且多次出现较高Accuracy； 同时， 实验也表明需综合考察模型在不同epochs和random seeds 下的稳定性。

上述结论为后续锁定固定的 target model 进行 Prompt Learning 验证奠定了坚实基础。

5.2 基于选定 GraphCL 权重的 Prompt Learning 验证

基于前期的超参数探索， 选定以下配置作为后续 prompt learning 实验的标准预训练

Target Model：

- Augmentation 1: dropN
- Augmentation 2: permE
- Ratio: 0.3
- Learning Rate: 0.01
- Epochs: 200

选取原因： 该配置在 200 epochs 下不仅取得了最佳表现， 且多次稳定出现， 有效排除了单次训练偶然高值的干扰。

基于此权重， 在 Cora (5-shot) 数据集上分别对比了 GPPT 与 RobustPrompt-T 的表现：

Prompt 方法	预训练权重	图状态(Graph Setting)	攻击方式 (Attack)	平均准确率 (Accuracy)
GPPT	pre_trained_model	Clean	None	0.4730
GPPT	pre_trained_model_raw	Clean	None	0.5710
GPPT	pre_trained_model_raw	Poisoned	Meta_Self-0.05	0.2790
RobustPrompt-T	pre_trained_model_raw	Clean	None	0.2762
		Poisoned	Meta_Self-0.05	0.1143

RobustPrompt-T	pre_trained_model_raw			
----------------	-----------------------	--	--	--

稳定性：在seed 1~5测试中，RobustPrompt-T 展现出了极高的不稳定性。在Clean 设定下，5 个 seed 的结果依次约为 0.5116、0.0685、0.1100、0.1067、0.3762，方差颇大；而在 Poisoned（攻击浓度0.05）设定下，结果依次约为 0.1410、0.0650、0.0890、0.1390、0.0880，整体准确率不仅偏低，且波动依然明显。

阶段性判断：GPPT方法的实验数据初步验证了当前污染数据的有效性、选定预训练设置的合理性、及我们对于GPPT实现的大致正确（达到了稍好的分类表现）。尖锐的矛盾在于，实验数据表明，RobustPrompt-T在表现上仍严重缺乏稳定性与鲁棒性。这凸显了套用现有防御机制的潜在问题，亟需进一步工作。

6. 当前阶段结论与阶段性总结

本项目已推进到预训练模型及预训练模型超参数的筛选+多种prompt learning机制进行攻防实验验证的阶段。

通过前期广泛的超参数枚举，我们锚定【dropN + permE, ratio 0.3, epoch 200】的GraphCL作为现阶段实验的预训练基座。

尖锐的矛盾在于，实验数据表明，RobustPrompt-T在表现上仍严重缺乏稳定性与鲁棒性。这凸显了套用现有防御机制的潜在问题，亟需进一步工作。

7. 后续工作

结合当前的进度及问题，后续工作围绕以下三点展开：

- a. 扩展测试污染浓度，并针对极低实验表现的模块实施严格的对照与源码级 debug；
- b. 优化过滤机制（Filtering Mechanism）：深入剖析 RobustPrompt 对 seed 敏感的根源，探索并改进 filter 模块（如融合同构与异构图特性的高适应性过滤器）；
- c. 广泛调研，探索潜在创新点。

8. 计算资源备忘

通过网易UU远程连接学校的跳板机并连接到其他的高性能电脑：

请自行登录，并连接跳板机。

验证码: tony1994

成功远程控制跳板机后，请再次使用ssh远程连接到3个远程高性能电脑（使用桌面的MobaXTerm软件），渠道如下：

5090：

ip address: 10.1.128.167

port number: 22

username: user

passwd: tony1994!

cs5090：

ip address: 10.1.19.49

port number: 22

username: tony

passwd: 123456

H100：

ip address: 10.1.19.47

port number: 2222

username: tony

passwd: 123456