

MEETING 13 • 2026-06-17

RobustPrompt-I 稳定性诊断 & Filtering Tips 隔离调参报告

RobustPrompt-I GPromptShield Cora Inductive MD-PT 5-Shot

实验日期：2026-06-08 ~ 06-09 • 数据集：Cora (GraphCL GCN 256d) • 攻击：Meta_Self (Metattack)

1. 执行摘要



核心问题：RobustPrompt-I 存在严重训练不稳定性。 84 次实验中 43 次（51%）全部 5 seed 损失为 NaN。无一实验达到 5/5 seed 稳定。对比 RobustPrompt-T（Meeting 12）100% seed 稳定率，**I 版本当前不可靠，不建议直接用于调参或论文实验。**但当训练不崩时，I 版本性能远超 T 版本（见下文）。

RobustPrompt-T (Meeting 12, Jun 4)

指标	值
实验总数	28
5/5 稳定率	100%
Best Clean (sim=0.2)	0.4398
Best Clean (deg=1)	0.4435
Best Clean (ood=0.4)	0.4490
Best Attacked 0.05	0.2485

RobustPrompt-I (本次实验, Jun 8-9)

指标	值
实验总数	84
5/5 稳定率	0%
Best Clean (sim=0.2, 2/5)	0.5780
Best Clean (deg=5, 1/5)	0.5930
Best Clean (sim=0.3, 1/5)	0.5750
Best Attacked 0.05 (ood=0.4, 1/5)	0.4440

2. sim_pt 独立调参

静默 DEGREE=-1, OOD=-1.0 · 基础配置 PROMPT_LR=0.001, PT=0.25, MSE=0.01

2.6

平均有效 seed / 实验

30 实验中仅
sim=0.2@ptb=0.0 有 2
有效 seed

0.5780

Best Clean (sim=0.2,
2/5)

T 版本 0.4398 → I 提升
+0.138

0.3840

Best Attacked 0.05
(sim=0.3, 2/5)

T 版本 0.2125 → I 提升
+0.172

Clean (ptb=0.0) — Per-Seed 详情

SIM	S1	S2	S3	S4	S5	有效	均值(VALID)
0.2	NaN	NaN	NaN	0.5800	0.5760	2/5	0.5780
0.3	0.5750	NaN	NaN	NaN	NaN	1/5	0.5750
0.4	NaN	NaN	NaN	NaN	NaN	0/5	—
0.5	NaN	NaN	NaN	NaN	NaN	0/5	—
0.6	NaN	NaN	NaN	NaN	0.4820	1/5	0.4820

Attacked (ptb=0.05) — Per-Seed 详情

SIM	S1	S2	S3	S4	S5	有效	均值(VALID)
0.2	NaN	0.2940	0.1940	NaN	NaN	2/5	0.2440
0.3	NaN	0.3890	NaN	NaN	0.3790	2/5	0.3840
0.4	NaN	NaN	NaN	NaN	0.2560	1/5	0.2560
0.5	0.2630	NaN	NaN	NaN	NaN	1/5	0.2630
0.6	NaN	NaN	NaN	NaN	NaN	0/5	—

sim_pt 小结: sim=0.2 和 0.3 在 clean 和 attacked 上各有 2 个有效 seed，是相对最稳定的区间。当不崩时，clean 0.578 碾压 T 的 0.440，attacked 0.384 碾压 T 的 0.213。但 sim≥0.4

后 NaN 率急剧上升。

3. degree_pt 独立调参

静默 SIM=-1.0, OOD=-1.0 · 基础配置同上

0.9

平均有效 seed / 实验

24 实验中仅 10 个有 ≥ 1 有效 seed

0.5930

Best Clean (deg=5, 1/5)

T 版本 0.3357 $\rightarrow$ I 提升 +0.257

0.2730

Best Attacked 0.05 (deg=1, 1/5)

T 版本 0.2448 $\rightarrow$ 相当

Clean & Attacked — Per-Seed 详情

DEG	PTB	S1	S2	S3	S4	S5	有效	均值(VALID)
1	0.0	NaN	NaN	NaN	NaN	NaN	0/5	—
1	0.05	NaN	NaN	NaN	NaN	0.2730	1/5	0.2730
2	0.0	NaN	NaN	NaN	0.5510	NaN	1/5	0.5510
2	0.05	NaN	NaN	NaN	NaN	NaN	0/5	—
3	0.0	NaN	NaN	NaN	NaN	NaN	0/5	—
3	0.05	NaN	NaN	0.2140	NaN	NaN	1/5	0.2140
5	0.0	NaN	NaN	NaN	0.5930	NaN	1/5	0.5930
5	0.05	NaN	NaN	NaN	NaN	NaN	0/5	—

degree_pt 小结：degree_pt 稳定性最差——24 实验中 14 个（58%）全 NaN。但当 deg=5 clean 时单 seed 可达 0.593。deg=1（T 版本最优）在 I 版本 clean 上反而全 NaN。说明 I 版本的 subgraph 采样对低度节点更敏感，容易触发 NaN。

4. out_detect_pt 独立调参

静默 SIM=-1.0, DEGREE=-1 • 基础配置同上

0.8

平均有效 seed / 实验

30 实验中仅 12 个有 ≥ 1 有效 seed

0.4440

Best Attacked 0.05 (ood=0.4, 1/5)

T 版本 0.2485 $\rightarrow$ I 提升 +0.196

0.1980

Best Attacked 0.1 (ood=0.5, 1/5)

T 在 0.1 仅 0.07

Clean & Attacked (0.05) — Per-Seed 详情

OOD	PTB	S1	S2	S3	S4	S5	有效	均值(VAID)
0.3	0.0	NaN	NaN	NaN	NaN	NaN	0/5	—
0.3	0.05	NaN	0.0690	NaN	NaN	NaN	1/5	0.0690
0.4	0.0	0.1310	NaN	NaN	NaN	NaN	1/5	0.1310
0.4	0.05	NaN	NaN	NaN	0.4440	NaN	1/5	0.4440
0.5	0.0	NaN	NaN	NaN	NaN	NaN	0/5	—
0.5	0.05	NaN	NaN	NaN	NaN	NaN	0/5	—
0.6	0.0	NaN	NaN	NaN	NaN	NaN	0/5	—
0.6	0.05	NaN	NaN	NaN	NaN	NaN	0/5	—
0.7	0.0	NaN	NaN	NaN	NaN	NaN	0/5	—
0.7	0.05	NaN	NaN	NaN	NaN	NaN	0/5	—

out_detect_pt 小结：ood=0.4 是唯一在 attacked 0.05 上单 seed 达到 0.444 的配置（T 版本 0.2485）。但 ood $\geq$ 0.5 后全 NaN。ood 检测可能引入过多边/节点扰动，放大 subgraph 采样的不稳定性。

5. 全污染浓度扫描（有效 seed ≥ 2 的实验）

所有 6 个 PTB 浓度 (0.0 ~ 0.25) 中仅 17/84 实验有 ≥ 2 有效 SEED

类型	阈值	PTB=0.0	0.05	0.1	0.15	0.2	0.25	有效/5
sim	0.2	0.5780	0.2440	0.1405	0.1510	—	0.0465	2,2,2,2,0,2
sim	0.3	0.5750	0.3840	0.1120	0.0907	0.0755	—	1,2,2,3,2,0
sim	0.4	—	0.2560	—	0.1710	0.1033	—	0,1,0,1,3,0
deg	5	0.5930	—	0.1577	0.1515	0.0670	0.0665	1,0,3,2,1,2
ood	0.5	—	—	0.1980	0.0910	—	0.0540	0,0,1,1,0,2

趋势： sim=0.2 和 sim=0.3 在低 ptb (0.0~0.15) 上有最多有效 seed（8-9/30）。高 ptb (0.2-0.25) 几乎全 NaN。说明攻击强度越大，subgraph 采样 + τ_{tune} 剪枝组合越不稳定。

6. RobustPrompt-I vs RobustPrompt-T 对比

维度	ROBUSTPROMPT-T (MEETING 12)	ROBUSTPROMPT-I (本次)
实验总数	28	84
5/5 seed 稳定率	100% (28/28)	0% (0/84)
≥2 valid seed 实验	100%	20% (17/84)
Clean 最佳 (sim)	0.4398 (sim=0.2, 5/5)	0.5780 (sim=0.2, 2/5)
Clean 最佳 (deg)	0.4435 (deg=1, 5/5)	0.5930 (deg=5, 1/5)
Clean 最佳 (ood)	0.4490 (ood=0.4, 5/5)	0.1310 (ood=0.4, 1/5)
Att 0.05 最佳	0.2485 (ood=0.4, 5/5)	0.4440 (ood=0.4, 1/5)
NaN 率与攻击强度	无关联	强正相关 (ptb ↑ → NaN ↑)
NaN 率与 filter 类型	无差异	ood > degree > sim

7. 不稳定性根因分析

1. Subgraph 采样边界效应

当 defense prompt (尤其是 ood_pt 和 degree_pt) 为大比例节点分配特殊 token 时, k-hop 子图可能包含过多 defense-token 节点。

这些节点的特征被 prompt token 替换后, 子图内的 message passing 可能产生极端 embedding, 导致 τ_{tune} 剪枝后图结构崩溃 (边数 $\rightarrow 0$ 或全为孤立节点), 进而 loss $\rightarrow \text{NaN}$ 。

2. τ_{tune} 在子图上的放大效应

在全图 (T) 上, τ_{tune} 剪掉少量边对整体信息流影响有限。但在 k-hop 子图 (I) 上, 每个子图仅 100-300 节点, 剪掉几条关键边就可能导致子图断开。

GNN₂ 在断开子图上 forward 时, 梯度可能爆炸 (节点 embedding 方差极大) $\rightarrow \text{NaN}$ 。

3. 梯度裁剪不足

当前梯度裁剪仅应用于 RobustPrompt-I 的 Tune() 方法 (clip_grad_norm_max_norm=1.0)。

但如果 NaN 发生在 forward 阶段 (GNN 内部数值溢出), 梯度裁剪无法阻止——loss 已经是 NaN 时 backprop 无效。

4. prompt_lr=0.001 可能偏低

当前实验固定使用 prompt_lr=0.001 (同事建议)。但 Meeting 10 显示 T 版本需要 prompt_lr ≥ 0.004 才能稳定训练。

过低的学习率在某些 seed 下可能导致 prompt 参数停在不利区域, 增加数值不稳定风险。

8. 下一步建议

 优先级 1

诊断 NaN 根因

在单个 seed 上复现 NaN，打印中间值：

- add_muti_pt 后 token 分布
- GNN₁ 中间 embedding 的 min/max/std
- τ_{tune} 剪枝前后边数变化
- 每个子图的连通性

目标：确认 NaN 发生在 forward 还是 backward。

 优先级 2

稳定后重跑精简版调参

解决 NaN 后：

- 仅调 sim_pt (0.2, 0.3, 0.4), clean+0.05
- prompt_lr 尝试 0.005, 0.01
- 先用 $\text{pt_threshold}=-1.1$ 禁用 τ_{tune} ，排除变量
- 每个配置跑 5 seed 确认稳定

 优先级 3

对比 T vs I 在同等条件

用同一组超参数同时在 T 和 I 上跑 clean：

- 确认 I 的高性能是否真实（非 outlier）
- 量化 I 相比 T 的精度提升幅度
- 确认 inductive 设定对鲁棒性的增益

Report generated 2026-06-17 • Meeting 13 • Experiment code:
exp_20260617_I_stability_tuning.sh (needs import fix before re-run) • Logs:
logs/RobustPrompt-I/ft_*_2026060[89]_*.log (84 files)

⚠ 本次实验的 Jun 17 运行因 GraphCL.py 导入 load4graph 失败而全部报错（已在 CLAUDE.md 中修复）。本报告分析的是 Jun 8-9 的 RobustPrompt-I 日志（同样参数，成功运行）。